COMANDI STATISTICA

Statistica descrittiva

| NOME | COMANDO | |
|---|--|--|
| Cancella tutto | rm(list=ls()) | |
| Vettore | vettore<-c() | |
| Lunghezza | str() → num [1:10] | |
| | length() → 10 | |
| Dati in ordine crescente | sort() | |
| Frequenza assoluta (moda) | table(a) | |
| Frequenza relativa | prop.table(b) | |
| Frequenza percentuale | prop.table(b)*100 | |
| Media, xbar | mean() | |
| Mediana | median() | |
| Media ponderata, wa | sum(a*freq a)/tot a) | |
| noura ponaorada, wa | con tot_a = sum(freq_a) | |
| Deviazione standard, s | sd o sqrt(var) | |
| Varianza, s^2 | var() | |
| Coefficiente di variazione, cv | sd()/mean() | |
| | con mean in valore assoluto | |
| Boxplot | <pre>boxplot(a,horizontal=TRUE,col="yellow")</pre> | |
| | boxplot(a,b,horizontal=TRUE, | |
| | main="titolo", | |
| | names=c("a","b"), | |
| | col=c("orange","lightblue")) | |
| Scatterplot $ ightarrow$ length uguale | plot(a,b,col="red") | |
| Confronto tra percentili 🗲 length non | qqplot(a,b,col="red") | |
| uguale | | |
| Istogramma | hist() | |
| | breaks=numero, è il n°di classi | |
| Diagramma a torta | pie(tabella frequenze) | |
| Diagramma a barre | barplot(tabella frequenze) | |
| Min, 1st qu., Mediam, Mean, 3rd qu., Max | summary() | |
| Percentile | quantile(vettore, k%) | |
| Covarianza | cov(x,y) | |
| Coefficiente di corr di Pearson, r | <pre>cor(x,y) devo avere sd() e cov()</pre> | |
| Retta di regressione | lm(y~x) | |
| Netta di legiessione | con y=output e x=input | |
| | y<-function(x) (m*x+q) | |
| Sovrapporre | abline() | |
| Valori attesi | attesi<-round(predict(reg), digits=0) | |
| | | |
| | setNames(attesi, vettore richiesto) | |
| Per agire con un comando sulla singola | comando(dataframe \$ singola variabile) | |
| variabile del dataframe | | |
| Estremi del range | range(dataframe \$ singola variabile) | |
| Più piccolo e più grande valore di tutta la | range(dataframe) | |
| tabella | | |
| Ampiezza del range | range(dataframe \$ singola variabile)[2]- | |
| | range(dataframe \$ singola variabile)[1] | |
| Intervallo interquartile | IQR(dataframe \$ singola variabile) | |
| (distanza tra q_3-q_1) | | |
| Parametri di centralità per tutte le coppie | summary(dataframe) | |
| di variabili | | |
| Parametri di dispersione per tutte le | cov(dataframe) | |
| coppie di variabili | | |
| (covarianza e coeff. Di Pearson) | cor(dataframe) | |
| | · | |

Probabilità

| P(A) | k/n |
|--|--|
| Unione | $A \cup B = \{x \in \Omega; x \in A \circ x \in B\}$ |
| Intersezione | $A \cap B = \{x \in \Omega; x \in A \in x \in B\}$ |
| Complementare | $A^c = \{x \in \Omega; x \notin A\}$ |
| | $(A \cup A^{\circ} C) = \Omega$ |
| | $(A \cap A \cap C) = 0$ |
| Assiomi di Kolmogorov | • 0≤ P(A)≤1 |
| Spazio di probabilità (Ω,a,P) | $\bullet P(\Omega) = 1$ |
| | · , |
| 1 Deck of the test | $\bullet A \cap B = 0 \rightarrow P(A \cup B) = P(A) + P(B)$ |
| 1. Probabilità del complementare | $P(A^c) = 1-P(A)$ |
| 2. Probabilità dell'evento impossibile | P(0) = 0 |
| 3. Probabilità dell'evento certo | $P(B) = P(B \cap A) + P(B \cap A^{C})$ |
| 4. Probabilità di ordinamento | $A \subset B \rightarrow P(A) \leq P(B)$ |
| 5. Probabilità dell'unione di eventi non | $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ |
| disgiunti | |
| 5bis. Estensione punto 5 | $P(A \cup B \cup C) = P(A) + P(B) + P(C)$ |
| | $-P(A \cap B) - P(A \cap C) - (B \cap C) + P(A \cap B \cap C)$ |
| Eventi indipendenti | $P(A \cap B) = P(A) * P(B)$ |
| | solo se A e B sono indipendenti |
| Spazio di probabilità uniforme | $P(A) = P(A) *p = A / \Omega $ |
| | $P(A \cap B) \le P(A) \le P(A \cup B)$ |
| Valore atteso=media, mu, E[x] | sum(x*x) |
| | n*p |
| Varianza, sigma2 | sum(x-mu) ² x |
| | n*p(1-p) |
| Deviazione standard, sigma | sqrt(sigma2) |
| n! | factorial(n) |
| (n k) | choose(n,k) |

| P(x=k) | $p(k) = P(x=k) = (n \ k) p^{k} (1-p)^{n-k}$ |
|-----------------------------|--|
| | dbinom(k,size=n,prop=p) |
| $P(a \le x \le b)$ | <pre>sum(dbinom(a:b, size=n, prop=p))</pre> |
| $P(a \le x < b)$ | <pre>sum(dbinom(a:b-1, size=n, prop=p))</pre> |
| P(a < x ≤ b) | <pre>sum(dbinom(a+1:b), size=n, prob=p))</pre> |
| $P(x \ge a) \circ 1-P(x=0)$ | <pre>sum(dbinom(a:n,size=n,prop=p))</pre> |
| P(x > a) | <pre>sum(dbinom(a+1:n,size=n,prop=p))</pre> |

| $P(z > a) \circ 1-P(z \le a)$ | 1-pnorm(a, mean=mu, sd=sigma) |
|-------------------------------|--|
| | <pre>pnorm(a, mean=mu, sd=sigma, lower.tail=FALSE)</pre> |
| P(a < Z < b) | pnorm(b,mean=mu,sd=sigma)- |
| | <pre>pnorm(a, mean=mu, sd=sigma)</pre> |
| P(x < a) | pnorm(a,mean=mu,sd=sigma) |

| DISTRIB. | DENSITA' pdf | RIPARTIZIONE cdf | QUANTILI ORDINE $lpha$ |
|--|------------------------------------|-------------------------------------|--|
| x~unif[a,b] uniforme | <pre>dunif(x,min=a,max=b)</pre> | <pre>punif(x,min=a,max=b)</pre> | qunif(α , min=a, max=b) |
| $\begin{array}{c} x \sim N \; (\mu , \delta^2) \\ \text{normale} \\ \text{standard} \end{array}$ | $dnorm(x,mean=\mu,sd=\delta)$ | pnorm(x,mean= μ ,sd= δ) | qnorm(α , mean= μ , sd= δ) |
| x=B(n,p) quantili | <pre>dbinom(x,size=n,prob=p)</pre> | <pre>pbinom(x,size=n,prob=p)</pre> | qbinom(α , size=n, prob=p) |

Statistica inferenziale

Media μ e deviazione standard σ NOTE

| Valore atteso | E[x]= μ |
|------------------------------|---|
| Varianza | $Var(x) = \sigma^2/n$ |
| Teorema del limite centrale | $x \sim N(\mu, \sigma^2/n)$ |
| | con n ≥ 30 quindi non necessaria normalità del campione |
| Errore statistico (E>0) | $E = Z \star \sigma / \sqrt{n}$ |
| | con $Z^* = Z_{1-\frac{\alpha}{2}}$ qnorm(1-(alpha/2), mean=0, sd=1) |
| Livello di fiducia | 1-α=% → α=1-cl |
| Intervallo di confidenza, cl | <pre>μ = xbar ± E IC=(xbar-E,xbar+E) IC<-xbar+c(-E,E)</pre> |

Media μ e varianza $\pmb{\sigma}^2$ $\underline{\text{NON}}$ NOTE, distr norm

| Valore atteso | E[x] = 0 |
|------------------------------|--|
| Varianza | Var(x) = n/n-2 |
| t di student | t_{n-1} |
| Errore statistico | $E = t^* s/\sqrt{n}$ |
| | con $t^* = t_{1-\frac{\alpha}{2},n-1}$ qt(1-alpha/2, df=n-1) |
| | se n>30 $t_{1-rac{lpha}{2},n-1}$ sostituito con $Z_{1-rac{lpha}{2}}$ |
| Livello di fiducia | $1-\alpha/2$ |
| | con n-1 gradi di libertà |
| Intervallo di confidenza, cl | μ = xbar \pm E |
| | <pre>IC=(xbar-E,xbar+E)</pre> |
| | IC<-xbar+c(-E,E) |

Proporzione p di una popolazione bernoulliana

| Proporzione campionaria, phat | phat=n°successi nel campione / n |
|-------------------------------|--|
| Ipotesi di lavoro | $n*phat \ge 5 e n*(1-phat) \ge 5$ |
| Errore statistico | $E = Z_{1-\frac{\alpha}{2}} * \sqrt{\frac{phat*(1-phat)}{n}}$ $qnorm(1-(alpha/2), mean=0, sd=1) $ |
| Livello di fiducia | 1-α=% → α=1-c1 |
| Intervallo di confidenza, cl | <pre>μ = phat ± E IC=(phat-E,phat+E) IC<-phat+c(-E,E)</pre> |

Stima della varianza, distr norm e varianza nota

| Distribuzione chi-quadro con n gradi di libertà | dchisq(x,df=n) |
|---|---|
| Quantili | $1*=X^2 \alpha/2$, n qchisq(alpha/2,df=n) |
| | $r*=X^2$ 1- $\alpha/2$, n qchisq(1-alpha/2,df=n) |

Stima della varianza, distr norm e varianza NON nota

| Livello di fiducia | 1-α |
|--------------------------|--|
| Quantili | $1*=X^2$ $\alpha/2$, $n-1$ qchisq(alpha/2, df=n-1) |
| | $r*=X^2$ 1- α /2, n-1 qchisq(1-alpha/2, df=n-1) qchisq(alpha/2, df=n-1, lower.tail = FALSE) |
| Intervallo di confidenza | $ \frac{(n-1)s^2}{r*}; \frac{(n-1)s^2}{l*} $ IC<-(n-1)*s2*c(1/rstar, 1/lstar) |

Livelli di confidenza minori forniscono stime intervallari più precise

TEST di ipotesi con popolazione bernoulliana $Z=rac{p-p0}{\sqrt{rac{p0(1-p0)}{n}}}$

| Test a una cosa destra | H0:p=p0 |
|---|--------------------------------|
| <pre>prop.test(x,n,p=p0,alternative="greater")</pre> | HA:p>p0 |
| con x=n° successi del campione, round(n*phat) n=ampiezza del campione | Pvalue=P(Z>z) |
| p0=parametro teorico di confronto | |
| Test a una coda sinistra | H0:p=p0 |
| <pre>prop.test(x,n,p=p0,alternative="less")</pre> | HA:p <p0< td=""></p0<> |
| | Pvalue=P(Z <z)< td=""></z)<> |
| Test a 2 code | H0:p=p0 |
| <pre>prop.test(x,n,p=p0,alternative="two.sided")</pre> | HA:p≠p0 |
| | Pvalue=2P(Z> z)=2(1-P(Z< z)) |

TEST di ipotesi per media con varianza NOTA $Z=rac{xbar-\mu 0}{rac{oldsymbol{\sigma}}{\sqrt{n}}}$

| <pre>Test a una cosa destra pvalue<-1-pnorm(z) pvalue<-1-pnorm(z,mean=0,sd=1,lower.tail=FALSE)</pre> | $H0: \mu = \mu 0$ $HA: \mu > \mu 0$ Pvalue = P(Z>z) |
|--|---|
| <pre>Test a una coda sinistra pvalue<-pnorm(z,mean=0,sd=1)</pre> | $H0: \mu = \mu 0$ $HA: \mu < \mu 0$ Pvalue = P(Z < z) |
| <pre>Test a 2 code > pvalue<-2*(1-pnorm(abs(z))) > pvalue<-2*pt(abs(z),lower.tail=FALSE)</pre> | H0: $\mu=\mu$ 0 HA: $\mu \neq \mu$ 0 Pvalue=2P(Z> z)=2(1-P(Z< z)) |

TEST di ipotesi per media con varianza NON NOTA $t=rac{xbar-\mu 0}{rac{S}{\sqrt{n}}}$

| | V |
|--|-----------------------------------|
| Test a una cosa destra | H0: μ=μ0 |
| <pre>t.test(x,mu=mu0,alternative="greater")</pre> | HA: μ>μ0 |
| | Pvalue=P(T>t) |
| Test a una coda sinistra | H0:μ=μ0 |
| <pre>t.test(x,mu=mu0,alternative="less")</pre> | HA: μ<μ0 |
| <pre>pvalue<-pt(t,df=(n-1))</pre> | Pvalue=P(T <t)< td=""></t)<> |
| Test a 2 code | H0: μ=μ0 |
| <pre>t.test(x,mu=mu0,alternative="two.sided")</pre> | HA: $\mu \neq \mu 0$ |
| <pre>pvalue<-2*pt(abs(t),df=(n-1),lower.tail=FALSE)</pre> | Pvalue= $2P(T> t)=2(1-P(T< t))$ |
| \rightarrow pvalue<-2*(1-pt(abs(t),df=(n-1))) | |

TEST di ipotesi per la varianza $(chi2)x^2 = \frac{(n-1)s^2}{\sigma l^2}$

| σ_0 | |
|--|--|
| Test a una cosa destra | $H0:\sigma^2 = \sigma 0^2$ |
| <pre>pvalue<-1-pchisq(chi2,df=n-1) pvalue<-pchisq(chi2,df=n-1, lower.tail=FALSE)</pre> | $HA:\sigma^2 > \sigma^0$ |
| | Pvalue=P(X>x ²) |
| Test a una coda sinistra | $H0:\sigma^2 = \sigma^{02}$ |
| pvalue<-pchisq(chi2,df=n-1) | HA:σ ² < σ0 ² |
| | Pvalue=P(X <x2)< td=""></x2)<> |
| <pre>Test a 2 code pvalue<-2*min(pchisq(chi,df=(n-1),lower.tail=TRUE),</pre> | $H0:\sigma^2 = \sigma 0^2$ |
| | $HA: \sigma^2 \neq \sigma O^2$ |
| | Pvalue=2min(P($X < x^2$);P($X > x^2$)) |

Test di ipotesi per la mediana, distrib NON nota = TEST DI WILCOXON

| Test a una cosa destra | H0:mediana=m |
|--|----------------------------|
| <pre>wilcox.test(x, mu=m, alternative="greater")</pre> | HA:mediana>m |
| Test a una coda sinistra | H0:mediana=m |
| <pre>wilcox.test(x, mu=m, alternative="less")</pre> | HA:mediana <m< th=""></m<> |
| Test a 2 code | H0:mediana=m |
| <pre>wilcox.test(x, mu=m, alternative="two.sided")</pre> | HA:mediana≠m |

❖ Test di confronto tra 2 proporzioni di 2 popolazioni bernoulliane

$$z = \frac{p1 - p2}{\sqrt{\frac{p(1-p)}{n1 + n2}}}$$

z test

❖ Test di confronto tra medie di 2 popolazioni

-varianza note

$$z = \frac{xbar - ybar}{\sqrt{\frac{\sigma x^2 + \sigma y^2}{nx + ny}}}$$

z test, con pvalue<-pnorm(z)</pre>

-varianze NON note, ma uguali

$$t = \frac{xbar - ybar}{sp\sqrt{\frac{1}{nx + ny}}} \quad sp = deviazione \ standard \ pooled$$

-varianze NON note, NON uguali

$$t = \frac{xbar - ybar}{\sqrt{\frac{sx^2 + sy^2}{nx + ny}}} f \text{ ha distribuzione di Fischer co } nA - 1 \text{ e } nB - 1 \text{ gradi di libert}$$

Test di confronto sulle varianze

$$f = \frac{s^2 A}{s^2 B}$$

Test di confronto tra mediane

| TEST di indipendenza | H0:le variabili sono indipendenti |
|--|---|
| = | - |
| n=(n°righe-1)*(n°colonne-1) | HA:le variabili non sono indipendenti |
| | costruiamo la tabella di contingenza: x<-rbind(rigasopra, rigasotto) |
| | chisq.test(x) |
| TEST di Shapiro-Wilk | H0:X ha distribuzione normale |
| IESI di Shapilo Wilk | HA:X NON ha distribuzione normale |
| | |
| | shapiro.test(x) |
| TEST di adattamento | H0:X=X0 (modello compatibile con i dati) |
| | HA:X≠X0 (modello NON compatibile con i dati) |
| | chisq.test(z,p=pt) |
| | con z=frequenze,pt=elementi |
| TEST di Kolmogorov-Smirnov | H0:la distribuzione si adatta al modello |
| | HA:la distribuzione NON si adatta al modello |
| | ks.test(x,"nome cdf",distribuzione) |
| Confronto tra distribuzioni di 2 | H0:X=Y (distrib. 2 popolaz. sono uguali) |
| popolazioni | HA:X≠Y (distrib. 2 popolaz. NON sono uguali) |
| | ks.test(x,y) |
| TEST ANOVA a una via | $H0: \mu = \mu 0 = \cdots = \mu k$ |
| distrib. normale e stesse varianze (anche non note) | HA:almeno una delle μ diversa dalle altre |
| | costruiamo un dataframe: |
| | <pre>l<-list(maggio=may,settembre=sep,dicembre=dec)</pre> |
| | d<-stack(1) |
| | oneway.test(colonna1~colonna2,data=d, |
| | var.equal=TRUE) |
| | var.equal=FALSE) → se non è |
| TEST di Kruskall Wallis | ipotizzabile l'uguaglianza tra le varianze |
| TEST OF Kruskail Wallis | H0: $\mu = \mu 0 = \dots = \mu k$ |
| | HA:almeno una delle μ diversa dalle altre |
| | costruiamo un dataframe: |
| | <pre>l<-list(maggio=may,settembre=sep,dicembre=dec) d<-stack(1)</pre> |
| | kruskal.test(colonnal~colonna2,data=d) |
| TEST di ipotesi per (rho)ρ=0 | H0:p=0 (NON c'è correlazione lineare) |
| | , |
| Pvalue piccolo → t grande → r prossimo a 1 Pvalue grande → t piccolo → r prossimo a 0 | HA:ρ≠0 (c'è correlazione lineare) |
| rvalue grande 7 [t]procoro 7 r prossimo a U | Cor(x, y) |
| | $\left(\begin{array}{c} n-2 \end{array} \right)$ |
| | $t=r\left(\begin{array}{c} n & 2 \\ \hline 1 & 2 \end{array}\right)$ $n-2$ gradi di libertà |
| | $t=r\left(\sqrt{rac{n-2}{1-r^2}} ight) n-2\ gradi\ di\ libert$ à |
| | Pvalue= $2P(T> t) \rightarrow cor.test(x,y)$ |
| TEST di pendenza e intercetta = 0 | H0: beta0=0 intercetta (beta1=0 pendenza) |
| 1201 al pendenza e intercetta — 0 | HA: beta0=0 intercetta (beta1=0 pendenza) |
| | reg<- lm(y~x) |
| | _ |
| | $summary(reg) \rightarrow summary(lm(y~x))$ |